



ITESO, Universidad Jesuita de Guadalajara

REINFORCEMENT LEARNING ENVIRONMENT

JESÚS ANDRÉS GARCÍA-CASARRUBIOS GONZÁLEZ

6 / 5 / 2026

ÍNDICE

SDP	3
EVALUACIÓN WALK-FORWARD	6
DATASET ANALYSIS	9
SEQUENTIAL DECISION MODELING (POWELL).....	10
ANÁLISIS.....	13
PRODUCTION FAILURE ANALYSIS	17
CONCLUSIÓN.....	19

Este proyecto desarrolla un marco de aprendizaje por refuerzo para el trading de BTCUSDT utilizando datos horarios que abarcan desde agosto de 2017 hasta abril de 2026. Más que centrarse en la implementación de algoritmos de aprendizaje, el enfoque principal se encuentra en la formulación del problema de trading como un proceso de decisión secuencial bajo el marco de Powell, así como en el diseño de un entorno de simulación realista.

Los mercados financieros presentan desafíos particulares para el RL, incluyendo la no estacionariedad, la predominancia del ruido sobre la señal y la presencia de costos de transacción. Estas características dificultan que los agentes puedan extraer señales predictivas de manera consistente, lo que con frecuencia conduce a comportamientos degenerados, como el sobretrading o el colapso hacia políticas triviales. Por ello, uno de los objetivos clave de este trabajo no es únicamente entrenar un agente, sino evaluar críticamente su comportamiento bajo supuestos realistas.

El problema se modela como un proceso de decisión semi-Markov, donde las acciones corresponden a la apertura de posiciones y las recompensas se materializan al cierre de estas. El entorno incorpora supuestos de ejecución realistas, incluyendo costos de transacción y horizontes finitos de mantenimiento de posiciones. La representación del estado se construye a partir de variables derivadas exclusivamente de información pasada del mercado, garantizando consistencia causal y evitando el lookahead bias.

Para evaluar el desempeño, se utiliza un esquema de validación walk-forward, junto con comparaciones contra benchmarks de buy-and-hold tanto en BTC como en el S&P 500 (aproximado mediante SPY). Los resultados evidencian las dificultades de aplicar RL en mercados financieros: si bien el agente logra aprender políticas de trading, no consigue superar estrategias simples debido a los costos de transacción, la falta de señales predictivas robustas y la inestabilidad en los comportamientos aprendidos.

Este trabajo demuestra que el diseño adecuado del entorno y una evaluación rigurosa son elementos críticos en el aprendizaje por refuerzo aplicado a finanzas, y que alcanzar rentabilidad es considerablemente más complejo que construir un sistema de aprendizaje funcional.

SDP

El problema de trading se formula como un Proceso de Decisión Secuencial dentro del marco de Powell, donde el objetivo es aprender una política que maximice el valor esperado de las contribuciones acumuladas a lo largo del tiempo.

1. Definición del estado

El estado en el tiempo (t) se define como:

$$[S_t = (S_t^P, S_t^I)]$$

donde:

- (S_t^P) (estado físico):
Incluye variables relacionadas con el portafolio y la ejecución:
 - capital actual
 - posición abierta implícita
 - tiempo transcurrido dentro de la posición
- (S_t^I) (estado de información):
Vector de características derivadas exclusivamente de datos históricos:
 - retornos logarítmicos (1h, 24h)
 - desviación respecto a medias móviles (SMA 24 y 168)
 - volatilidad de corto y largo plazo
 - rango high-low
 - z-scores de volumen y actividad de trading

Estas variables se construyen únicamente con información disponible en (t), garantizando ausencia de lookahead bias.

El análisis exploratorio sobre el conjunto de entrenamiento muestra autocorrelaciones débiles en retornos pero mayor persistencia en volatilidad y volumen, lo cual justifica su inclusión como parte del estado informacional.

2. Espacio de acciones

El conjunto de acciones es discreto:

$$[A_t \in \{0, 1, 2\}]$$

donde:

- 0: no operar (mantener posición o estar en cash)
- 1: abrir posición larga
- 2: abrir posición corta

3. Dinámica de transición (semi-Markov)

El sistema sigue una formulación semi-Markov, donde las transiciones dependen de la duración de las posiciones abiertas.

En la implementación final del entorno, las posiciones se cierran únicamente al alcanzar un horizonte máximo de permanencia (`max_holding`).

Aunque durante el diseño conceptual se consideró incorporar mecanismos de stop-loss y take-profit, estos fueron descartados en la implementación final debido a que aumentaban significativamente la complejidad del entorno y generaban mayor inestabilidad en el entrenamiento inicial del agente.

Como resultado, cada transición semi-Markov ocurre después de un número fijo de periodos, determinado por el parámetro de holding máximo.

Si dentro de una misma vela (barra horaria) se alcanzan simultáneamente el stop-loss y el take-profit, se asume que el stop-loss se ejecuta primero.

4. Función de contribución (recompensa)

La función de recompensa se define como el retorno neto de la operación ajustado por costos de transacción:

$$R = (r_{trade} - fees) \cdot \alpha$$

donde:

- r_{trade} es el retorno bruto de la operación
- `fees` representa el costo de transacción de 0.125% por lado
- α es un factor de escalamiento utilizado para amplificar la señal de recompensa durante el entrenamiento

En la implementación final se utilizó una recompensa lineal escalada (`reward = net * 10`) en lugar de una función no lineal como `tanh`, ya que las pruebas preliminares mostraron que la saturación inducida por `tanh` dificultaba la diferenciación entre operaciones moderadamente buenas y extremadamente buenas o malas.

5. Episodios y entorno

Dado que el mercado de criptomonedas opera de forma continua (24/7), un episodio se define como un intervalo fijo de tiempo dentro del esquema walk-forward (folds temporales). Cada fold representa un periodo distinto de entrenamiento y evaluación, respetando la estructura temporal del mercado.

6. Justificación del diseño

La selección del estado informacional se basa en propiedades empíricas observadas en el conjunto de entrenamiento:

- baja autocorrelación en retornos → limita predictibilidad directa
- mayor persistencia en volatilidad → útil como señal contextual
- dependencia del volumen → proxy de actividad del mercado

Se evaluaron alternativas como:

- uso de precios absolutos (rechazado por no estacionariedad)
- inclusión de indicadores técnicos adicionales sin normalización (rechazado por inestabilidad)

7. Objetivo del problema

Siguiendo Powell, el objetivo es encontrar una política (π^*) que maximice:

$$[\max_{\pi} \mathbb{E} \left[\sum_t C_t^{\pi} \right]]$$

donde el agente de RL se utiliza como mecanismo de búsqueda en el espacio de políticas.

EVALUACIÓN WALK-FORWARD

Para la evaluación del modelo se utiliza un esquema de validación tipo walk-forward con ventana expansiva de cuatro pliegues (folds), el cual respeta la estructura temporal de los datos financieros y evita cualquier tipo de fuga de información hacia el futuro.

En cada fold, el conjunto de entrenamiento se expande progresivamente mientras que los periodos de validación y prueba avanzan en el tiempo. Aunque el protocolo conceptual incluye un conjunto de validación para selección de hiperparámetros, en la implementación práctica los experimentos se enfocaron principalmente en evaluación

walk-forward out-of-sample debido a limitaciones computacionales y de tiempo de entrenamiento.

En algunos periodos el modelo tiende a sobre-operar, generando un número elevado de transacciones sin mejora en el rendimiento acumulado, mientras que en otros periodos reduce significativamente su actividad, lo que indica posibles colapsos parciales de la política aprendida.

En conjunto, estos resultados sugieren que el agente no logra identificar una señal de trading robusta y estable, sino que responde a patrones ruidosos en el espacio de estados.

1. Esquema de evaluación

El protocolo utilizado es el siguiente:

- **Fold 1**
 - Train: 2017–08 a 2021–12
 - Validación: 2022
 - Test: 2023
- **Fold 2**
 - Train: 2017–08 a 2022–12
 - Validación: 2023
 - Test: 2024
- **Fold 3**
 - Train: 2017–08 a 2023–12
 - Validación: 2024
 - Test: 2025
- **Fold 4**
 - Train: 2017–08 a 2024–12
 - Validación: 2025
 - Test: 2026 (enero a abril)

Este diseño permite evaluar la estabilidad temporal del agente y su capacidad de generalización en distintos regímenes de mercado.

2. Entrenamiento por fold

Se entrena un modelo independiente de aprendizaje por refuerzo (PPO) para cada fold, utilizando únicamente los datos del periodo de entrenamiento correspondiente. Esto garantiza que cada evaluación en test sea completamente fuera de muestra (*out-of-sample*).

3. Métricas de evaluación

Para cada fold se reportan las siguientes métricas:

- Retorno total del agente (RL strategy return)
- Retorno de buy-and-hold en BTCUSDT
- Retorno del índice SP500 (proxy SPY)
- Sharpe ratio
- Maximum Drawdown

Posteriormente, los resultados se agregan calculando la media y la desviación estándar a través de los cuatro folds, lo que permite evaluar tanto el desempeño esperado como su estabilidad.

4. Benchmarks

El desempeño del agente se compara contra dos estrategias pasivas:

4.1 Buy-and-hold en BTCUSDT

Se mantiene una posición larga continua en BTCUSDT durante todo el periodo de test.

4.2 Índice SP500 (proxy SPY)

Se utiliza el ETF SPY como aproximación del rendimiento del mercado accionario estadounidense.

5. Costos de transacción

En todos los casos (estrategia del agente y benchmarks) se aplica un costo de transacción fijo del 0.125% por operación, asegurando consistencia en la comparación y evitando sesgos a favor de estrategias de alta frecuencia.

6. Métricas adicionales requeridas

El framework fue diseñado para permitir el cálculo de métricas adicionales como Sortino ratio, Calmar ratio, turnover y duración promedio de trades. Sin embargo, debido a la inestabilidad observada en las políticas aprendidas y a la baja consistencia operativa del agente, el análisis principal se centra en:

- Retorno acumulado
- Benchmark comparison
- Drawdown
- Comportamiento operativo del agente

7. Interpretación de la evaluación

Este esquema permite evaluar no solo la rentabilidad del agente, sino también su estabilidad temporal y robustez ante distintos regímenes de mercado. En particular, la comparación con múltiples benchmarks proporciona una referencia clara sobre si el agente añade valor económico real o simplemente replica comportamientos pasivos del mercado.

DATASET ANALYSIS

El conjunto de datos utilizado corresponde a precios horarios de BTCUSDT desde agosto de 2017 hasta abril de 2026, con un total aproximado de 75,558 observaciones. A partir de este dataset se construyen variables derivadas exclusivamente de información histórica, garantizando consistencia causal.

El análisis exploratorio permite identificar distintos regímenes de mercado a lo largo del periodo de estudio:

1. 2017–2018: Régimen de alta especulación y burbuja

Periodo caracterizado por un fuerte crecimiento seguido de una caída abrupta. Se observan altos niveles de volatilidad y drawdowns significativos posteriores al pico de finales de 2017. Este régimen presenta fuerte no estacionariedad.

2. 2019–2020: Consolidación y transición estructural

Fase de recuperación con menor volatilidad relativa. El mercado muestra comportamiento más lateral con periodos de acumulación prolongados, especialmente previo al shock de 2020.

3. 2020–2021: Expansión post-crisis

Periodo de fuerte tendencia alcista impulsado por condiciones macroeconómicas globales. Alta correlación en retornos y persistencia de tendencia, lo cual favorece estrategias momentum.

4. 2022–2026: Régimen mixto y alta incertidumbre

Incluye correcciones severas, recuperación parcial y nuevos ciclos de volatilidad. Este régimen es particularmente relevante para la evaluación del modelo, ya que coincide con los folds de validación y prueba más recientes.

Estos regímenes evidencian que el entorno no es estacionario, lo cual justifica el uso de validación walk-forward y modelos adaptativos.

SEQUENTIAL DECISION MODELING (POWELL)

El problema de trading se formula como un Proceso de Decisión Secuencial bajo el marco de Powell.

1. Estado

El estado se define como:

$$[S_t = (S_t^P, S_t^I)]$$

Estado físico (S_t^P)

- capital disponible
- posición actual (long/short/cash implícito)
- tiempo de permanencia en la posición

Estado informacional (S_t^I)

Vector de variables construidas con información histórica:

- retornos logarítmicos (1h, 24h)
- desviaciones de medias móviles (24h, 168h)

- volatilidad de corto y largo plazo
- rango high-low
- z-scores de volumen y actividad

2. Decisión

$[A_t \in \{0, 1, 2\}]$

- 0: no operar
- 1: abrir posición larga
- 2: abrir posición corta

3. Información exógena

Incluye la realización del precio en el siguiente periodo:

- Open, High, Low, Close del siguiente intervalo
- shocks de mercado no observables en el estado

4. Función de transición

El sistema es semi-Markov:

$[S_{t+1} = S^M(S_t, A_t, W_{t+1})]$

donde la posición se mantiene activa hasta que ocurre uno de los siguientes eventos:

- expiración del horizonte máximo de tenencia
- activación de stop-loss
- activación de take-profit
- cierre implícito por el agente

Dado que los datos son OHLC, se asume una regla conservadora:

si stop-loss y take-profit ocurren en la misma vela, el stop-loss se ejecuta primero.

5. Función de contribución

La recompensa se define como:

- retorno neto de la operación
- ajustado por costos de transacción (0.125% por lado)

La recompensa se asigna al cierre de la posición, lo cual mejora la asignación de crédito en un entorno semi-Markov.

6. Objetivo

$$[\max_{\pi} \mathbb{E} \left[\sum_t C_t^\pi \right]]$$

donde el agente busca maximizar la suma esperada de contribuciones acumuladas.

7. Justificación de decisiones de diseño

Estado informacional

- **Elegido:** features de retornos, volatilidad y volumen
- **Alternativa:** usar precios crudos o indicadores adicionales sin normalización
- **Rechazo:** los precios crudos generan no estacionariedad fuerte y los indicadores adicionales no mejoraban desempeño en validación inicial

Acción discreta

- **Elegido:** acciones discretas (long/short/hold)
- **Alternativa:** acciones continuas de sizing
- **Rechazo:** mayor inestabilidad y dificultad de convergencia en pruebas iniciales

Horizonte de holding

- **Elegido:** max_holding fijo
- **Alternativa:** horizonte dinámico aprendido
- **Rechazo:** complejidad adicional sin mejora significativa en validación

Recompensa

- **Elegido:** PnL ajustado con tanh
- **Alternativa:** Sharpe por episodio o reward por paso
- **Rechazo:** Sharpe no es Markoviano y reward por paso generaba ruido excesivo

ANÁLISIS

El análisis de operaciones se centra en la identificación de los trades más relevantes en términos de pérdidas dentro del conjunto de prueba, agregando los resultados de los cuatro folds del esquema walk-forward.

1. Peores trades (máximas pérdidas)

Se identificaron los tres trades con mayor pérdida acumulada. Para cada uno de ellos se analiza:

- Fecha y precio de entrada
- Fecha y precio de salida
- Motivo de cierre (horizonte máximo, stop-loss o take-profit)
- Estado del mercado en el momento de entrada

Interpretación general de los trades perdedores

Los trades con mayores pérdidas comparten patrones comunes:

- Entradas realizadas durante periodos de alta volatilidad sin tendencia clara
- Reversiones abruptas inmediatamente después de la entrada
- Falta de señal direccional robusta en el estado informacional

Esto sugiere que el agente tiende a sobre-operar en entornos ruidosos, interpretando fluctuaciones de corto plazo como oportunidades de trading.

Posibles mejoras

Para evitar este tipo de fallos sería necesario:

- Incluir variables de régimen de mercado (trend vs mean reversion)

- Mejorar la representación del estado con métricas de incertidumbre o volatilidad estructural
- Introducir penalización explícita por drawdown o exposición en periodos de alta incertidumbre
- Replantear la función de recompensa para reducir sensibilidad a ruido intradiario

INTERPRETACIÓN DE LOS RESULTADOS

Los resultados evidencian que el agente no logra generar una estrategia rentable ni robusta bajo distintos regímenes de mercado. Aunque el modelo sí aprende políticas activas de trading y ejecuta operaciones en todos los folds, dichas decisiones no producen retornos ajustados por riesgo competitivos frente a estrategias pasivas simples.

La estrategia de RL queda considerablemente por debajo del benchmark de buy-and-hold en BTCUSDT en casi todos los folds. Esto es particularmente evidente en:

- Fold 1:
BTC presenta un rendimiento superior al 155%, mientras que el agente pierde aproximadamente 40%.
- Fold 2:
BTC mantiene un rendimiento positivo fuerte (+118%), pero el agente continúa generando pérdidas.

Incluso en los periodos donde BTC presenta desempeño débil o negativo (folds 3 y 4), el agente tampoco logra capitalizar correctamente las oportunidades del mercado, manteniendo retornos negativos significativos.

Asimismo, el benchmark del SP500 supera consistentemente al agente con menor volatilidad y drawdowns considerablemente más bajos.

El Sharpe ratio promedio negativo (-1.46) indica que el sistema produce retornos negativos ajustados por volatilidad. Esto implica que:

```
===== FOLD 1 =====
Train size: 9236
Test size: 2185
Trades: 26
```

```
===== FOLD 2 =====
Train size: 11426
Test size: 2191
Trades: 196
```

```
===== FOLD 3 =====
Train size: 13616
Test size: 2075
Trades: 230
```

```
===== FOLD 4 =====
Train size: 15812
Test size: 643
Trades: 67
```

- la estrategia no compensa el riesgo asumido,
- existe alta variabilidad en los resultados,
- y los trades generan ruido más que señal estadística explotable.

El fold 3 presenta el peor desempeño con un Sharpe de aproximadamente -3.19, reflejando un periodo particularmente adverso para la política aprendida.

```
===== RESULTADOS =====
fold  rl_return  btc_hold    sp500    sharpe    max_dd  trades
0      1  -0.395975  1.551013  0.267092 -0.901282 -0.396734    26
1      2  -0.093893  1.185413  0.255893 -0.111456 -0.461984   196
2      3  -0.644814 -0.057386  0.180090 -3.193636 -0.685942   230
3      4  -0.224321 -0.118910  0.047894 -1.619483 -0.295296    67
```

El Maximum Drawdown promedio cercano al -46% muestra que el agente experimenta pérdidas acumuladas severas durante los periodos de prueba.

Esto sugiere:

- ausencia de mecanismos efectivos de control de riesgo,
- dificultad para adaptarse a cambios de régimen,
- y tendencia a mantener posiciones incorrectas durante movimientos adversos prolongados.

```
===== PROMEDIOS =====
fold          2.500000
rl_return     -0.339751
btc_hold       0.640032
sp500          0.187742
sharpe        -1.456464
max_dd        -0.459989
trades       129.750000
```

El fold 3 alcanza un drawdown cercano al -69%, indicando que el modelo puede entrar en ciclos persistentes de malas decisiones bajo ciertas condiciones de mercado.

El número de operaciones varía significativamente entre folds:

- Fold 1: 26 trades
- Fold 2: 196 trades
- Fold 3: 230 trades
- Fold 4: 67 trades

Esta variabilidad indica que la política aprendida es altamente sensible al régimen de mercado. En algunos periodos el agente reduce significativamente su actividad, mientras que en otros sobre-opera agresivamente sin mejorar el desempeño.

La combinación de:

- alto número de operaciones,

- costos de transacción,
- y señales débiles,

provoca erosión sistemática del capital.

Esto es consistente con uno de los problemas clásicos del RL financiero: el agente aprende patrones espurios o ruido estadístico en lugar de relaciones predictivas robustas.

Los resultados muestran además que el comportamiento del agente no es estable entre folds:

- algunos periodos generan relativamente pocas operaciones,
- otros inducen trading excesivo,
- y el desempeño cambia drásticamente dependiendo del régimen del mercado.

Esto sugiere que el modelo no aprende una política generalizable, sino comportamientos altamente dependientes de las condiciones específicas del conjunto de entrenamiento.

2. Periodo de mayor drawdown

El mayor drawdown del agente ocurre en periodos de alta volatilidad y cambios bruscos de tendencia, particularmente en fases de transición de régimen (por ejemplo, caídas rápidas seguidas de consolidación).

Durante estos periodos, el agente mantiene posiciones abiertas que son rápidamente invalidadas por movimientos adversos del mercado, lo que amplifica las pérdidas acumuladas.

Comportamiento observado

- Concentración de trades consecutivos en la misma dirección
- Falta de adaptación rápida al cambio de régimen
- Persistencia de señales falsas en el estado informacional

3. Correlación con BTC

Se observa una correlación positiva entre los retornos del agente y los retornos de BTCUSDT.

Esto sugiere que, en parte, la estrategia aprendida se comporta como:

una versión apalancada o filtrada de una posición larga en BTC

En otras palabras, el agente no está generando completamente una estrategia independiente del activo subyacente, sino amplificando parcialmente su dirección.

PRODUCTION FAILURE ANALYSIS

El simulador asume que las órdenes se ejecutan al precio observado en los datos OHLC de la vela correspondiente (open, high, low o close dependiendo del evento de cierre de la posición). Este supuesto implica una ejecución perfecta sin deslizamiento (*slippage*) ni impacto de mercado.

En un entorno real, este supuesto no es válido. Al intentar ejecutar órdenes de tamaño significativo:

- **El precio de ejecución puede desviarse del precio teórico del modelo**
- La liquidez disponible en ese nivel de precio puede ser insuficiente
- Órdenes de mercado pueden mover el precio adversamente

Esto implica que los retornos simulados probablemente sobreestiman el desempeño real del sistema.

2. Latencia

El modelo asume ejecución instantánea de decisiones. Sin embargo, si el modelo requiere aproximadamente 2 segundos para inferencia:

- En un entorno de datos horarios, la latencia no es crítica en términos de frecuencia de decisión
- Sin embargo, cualquier retraso en la llegada del dato (por ejemplo, recibir la vela con retraso de 1 barra) invalida la señal, ya que el estado deja de reflejar la información actual del mercado

En consecuencia, el sistema es sensible principalmente a la sincronización del feed de datos más que al tiempo de inferencia en sí.

3. Capacidad y crowding

Si múltiples fondos implementaran estrategias similares basadas en señales de retornos, volatilidad y momentum:

- El alpha observado probablemente se reduciría o desaparecería rápidamente
- La estrategia se volvería competitiva contra otros agentes que reaccionan a las mismas señales
- El mercado se ajustaría eliminando parcialmente la ventaja estadística explotada por el modelo

En este contexto, la principal contraparte del agente son market makers y otros sistemas cuantitativos que proveen liquidez y absorben desbalances temporales de orden.

Esto implica que el rendimiento del modelo es sensible a efectos de saturación (*crowding*).

4. Cambio de régimen

El periodo de prueba incluye distintos regímenes de mercado (2023–2026), sin embargo, no garantiza cobertura de todos los posibles entornos futuros.

En escenarios alternativos:

- Regímenes tipo 2018 (bear market prolongado): El modelo puede fallar al mantener posiciones largas en entornos bajistas persistentes.
- Regímenes tipo 2022 (alta volatilidad y tightening macroeconómico): Aumenta la frecuencia de falsas señales debido a rupturas estructurales en correlaciones históricas.
- Regímenes no observados en entrenamiento: El modelo puede degradarse significativamente debido a la dependencia de patrones estadísticos históricos.

Features más vulnerables a cambio de régimen:

- retornos de corto plazo (ret_1h, ret_24h)
- volatilidad histórica (vol_24, vol_168)
- relaciones volumen-precio (vol_usdt_z, tradecount_z)

En general, cualquier variable basada en estadísticas móviles es susceptible a degradación bajo cambios estructurales del mercado.

CONCLUSIÓN

En conjunto, los resultados demuestran que construir un entorno funcional de Reinforcement Learning para trading es considerablemente más sencillo que obtener rentabilidad consistente en mercados reales.

Aunque el agente logra interactuar correctamente con el entorno, ejecutar operaciones y aprender políticas activas, el desempeño final evidencia las dificultades fundamentales del RL aplicado a finanzas:

- baja señal predictiva en retornos financieros,
- no estacionariedad,
- sensibilidad a costos de transacción,
- sobreajuste a regímenes específicos,
- y alta fragilidad ante cambios de mercado.

Por lo tanto, el principal aporte del proyecto no radica en haber construido una estrategia rentable, sino en demostrar de manera rigurosa los desafíos prácticos y metodológicos asociados al uso de Reinforcement Learning en trading algorítmico.